





Logistic Regression and KNN

اللَّهُمَّ صَلِّ عَلَى مُحَمَّدٍ وَعَلَى آلِ مُحَمَّدٍ، كَمَا صَلَّيْتَ عَلَى إِبْرَاهِيمَ، وَبَارِكْ عَلَى مُحَمَّدٍ وَعَلَى آلِ مُحَمَّدٍ،
كَمَا بَارَكْتَ عَلَى آلِ إِبْرَاهِيمَ، فِي الْعَالَمِينَ، إِنَّكَ حَمِيدٌ مَجِيدٌ

By: Muhammed Gamal Maklad

in [My LinkedIn](#)



أحنا في **Linear Regression** كنا بنحاول نوصل ل **Best Fit Line** طب أنا أيه يضمنلي ان أصلا أضمن ان في خط ممكن يقسم ال **Classes** اللي عندي ؟ يعني زي اللي في الصورة علشان كده في ساعات علشان اقسم ال **Classes** ممكن أكون محتاج **Curve** فعلشان كده هنستخدم ال **sigmoid** زي ما شرحنا اني هي عبارته عن **Function** بيكون **Threshold** بتاعها ب 0.5 و لو لقيمه اللي جايه ليها أصغر من 0.5 برجعها ب 0 لو القيمه أكبر من 0.5 هرجعها ب 1

$$z = b + w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + \dots + w_Nx_N$$

$$y' = \frac{1}{1 + e^{-z}}$$

أيوه يعني الكلام ده هيتعمل ازاى يا جيمي بص ال **Z** دي عبارته عن قانون **Linear Regression** فلو ال **Z** راجع بقيمو سالبه فالسالب ده هيبقي موجب يعني لو راجع ب 2 فكدته ناتج هيكون ب 0.89 فكدته اكبر من 0.5 فهرجعه ب 1 تمام ؟

$$z = \log\left(\frac{y}{1-y}\right)$$

هنا لو عندي **Output 2** فكدته ال **Y** هي ال **Probability** بتاعت حدوث ال **Output** الأول و **Y-1** احتمال حدوث ال **Output** الثاني تمام ؟

❖ Regularization:

- **Overfitting:** Creating a model that matches the training data so closely that the model fails to make correct predictions on new data.
- **Regularization:** any mechanism that **reduces overfitting**.
- **Regularization Rate λ** A number that specifies the relative importance of regularization during training. Raising the regularization rate reduces overfitting but may reduce the model's predictive power (**increase loss**). Conversely, reducing or omitting the regularization rate increases overfitting.


$$\text{minimiz}(\text{loss function} + \lambda(\text{regularization}))$$

ال **regularization** هو محاوله مننا اننا نقضي علي اصعب مشكله في الماشيين ليرنج الا و هي ال **Overfitting** عن طريق أول حاجه اني اشيل الفيتشر اللي ملهاش أي تلاته لازمه اللي بتؤدي ان الموديل بحصله **Overfitting** عندي منها نوعين **L1, L2 regularization**.

L1 regularization	L2 regularization
Penalizes weights based on the sum of their absolute values	Penalizes weights based on the sum of their squared values.
Used in Feature selection	Suitable if data contains outliers
makes models simpler by removing some features completely.	keeps all features but reduces the impact of less important ones.
$L_1 \text{ loss} = \sum_{i=0}^n y_i - y'_i $	$L_2 \text{ loss} = \sum_{i=0}^n (y_i - y'_i)^2$


L1 أو Lasso هو كل اللي بيعمله انه بيحاول يخلي ال Feature اللي ملهاش لازم ال Weight بتاعها ب 0 فبناء عليه هيشيلها بحيث انها متلغبطش ال موديل و ده حلو أوي في Feature selection اما L2 أو Ridge هو بيحسب ال التربع لل Weight و ال Feature اللي ملهاش لازمه بيخلي ال Weight بتاعها بيقترب من ال 0 فده كويس جدا لما يكون في Outlier و يروح يضرب القيمة دي في Lambda .

- **Regularization rate (lambda):** The Greek character lambda typically symbolizes the regularization rate. $\text{minimiz}(\text{loss function} + \lambda(\text{regularization}))$

high regularization rate	low regularization rate
reducing the chances of overfitting.	increasing the chances of overfitting.
normal distribution ,a mean weight of 0.	a histogram of model weights with a flat distribution.
	

❖ K-Nearest Neighbors (KNN):

- **K-Nearest Neighbors** algorithm is a supervised learning classifier, which uses proximity to make predictions/classifications about the group of individual data points.
- It is based on the assumption that similar points can be found near one another.



في ال KNN بيعتمد علي المسافه بمعنى انا دلوقتي عندي النجمه دي انا عاوزه أحدد هي تبع انهي Class لو انا قولتله $K=3$ و هنا عدد neighbors اللي هبصلهم فهو بيشف ايه أقرب 3 عناصر منها مسافه و بناء ع الكلاس اللي هيكون له أكبر عدد فبيحطها معاها يعني هنا أقرب 3 عناصرو عبارته عن 2 مثلث و 1 مربع معني كده انه هيعتبرها انها مربع . قوانين حساب المسافه تحت اهي


Euclidean Distance	Manhattan distance	Minkowski Distance	Hamming Distance
المسافه بين نقطتين ع خط مستقيم	المسافه بين نقطتين ع مجسم زي المسافه بين بلدين	distance measure is the generalized form of Euclidean and Manhattan distance metrics.	used with Boolean or string vectors, identifying the points where the vectors do not match.
$d(x,y) = \sqrt{\sum_{i=1}^n (y_i - x_i)^2}$	$= \left(\sum_{i=1}^m x_i - y_i \right)$	$= \left(\sum_{i=1}^n x_i - y_i ^p \right)^{\frac{1}{p}}$	Hamming Distance = $D_H = \left(\sum_{i=1}^k x_i - y_i \right)$ $\begin{matrix} x=y & D=0 \\ x \neq y & D \neq 1 \end{matrix}$

✚ it is recommended to have an **odd** number for k to avoid ties in classification

❖ Cross-Validation:

➤ k-fold Cross-Validation:

- ✓ Partitions data into k equal subsets (or folds).
- ✓ Each subset is used once as a validation set, while the model is trained on the remaining k-1 subsets.
- ✓ Process repeats k times, with each subset serving as the validation set once.
- ✓ The average error across all k runs is reported as E.
- ✓ Popular for cross-validation but can be time-consuming due to repeated model training.



تخيل انت جايك داتا وليكن من 1000 صف قولت هتقسمهم 5 folds هتعمل منهم 800 ك
Train و 200 ك Test فعلشان تعمل Cross-Validation انت هتروح بدل قسمتهم 5
folds ببقية زي متقول هتدرب الموديل 5 مرات مره اول 200 ف هيكونوا Test و ال 800
التانيين هيبقوا Train و نحسب Accuracy تاني مره تاني 200 صف هيكونوا Test و
ال 800 التانيين هيبقوا Train و نحسب Accuracy و هكذا و في الاخر نطلع ال
Average Accuracy .

❖ Applications of KNN in Machine Learning:

- **Data preprocessing:** Datasets frequently have missing values, but the KNN algorithm can estimate for those values in a process known as missing data imputation.
- **Recommendation Engines:** Using clickstream data from websites, the KNN algorithm has been used to provide automatic recommendations to users on additional content. a user is assigned to a particular group, and based on that group's user behavior, they are given a recommendation.
- **Healthcare:** KNN has also had application within the healthcare industry, making predictions on the risk of heart attacks and prostate cancer. The algorithm works by calculating the most likely gene expressions.
- **Pattern Recognition:** KNN has also assisted in identifying patterns, such as in text and digit classification. This has been particularly helpful in identifying handwritten numbers that you might find on forms or mailing envelopes.